Sistema de Recomendação de Livros Nacionais

Projeto 1 — Introdução à Inteligência Artificial
Universidade de Brasília — Departamento de Ciência da Computação
Turma 01 — 2026/1 | Prof. Díbio

Ana Caroline Freitas Brito (242001526)
Márcio Vinícius da Silva Guimarães (242001553)
Vitor Ignacio dos Santos Valcarcel (242010006)

28 de abril de 2026

Resumo

Este projeto implementa um sistema de recomendação por conteúdo e colaborativo para uma livraria virtual de obras nacionais. A aplicação utiliza dados simulados para avaliar e sugerir obras da literatura brasileira baseando-se em três características principais: gênero literário, período histórico e estilo.

1 Proposta de Tema e Catálogo de Produtos

Tema: Livraria Virtual de Obras Nacionais
Padrão de avaliação: escala inteira de 1 a 5 (1 = péssimo, 5 = excelente)

O catálogo possui 55 livros nacionais, cada qual categorizado com 3 características principais:

- **Gênero**: Romance, Poesia, Conto, Teatro, Fábula, Narrativa, etc.
- **Período**: Século XIX, Século XX, Século XXI.
- **Estilo**: Realismo, Naturalismo, Romantismo, Modernismo, etc.

O sistema oferece três modelos de recomendação: Filtragem por Conteúdo (TF-IDF), Filtragem Colaborativa (User-Based kNN) e um Modelo Híbrido.

2 Organização dos Dados e Matriz de Utilidade

A matriz de utilidade (*utility matrix*) é a estrutura principal utilizada pelo algoritmo colaborativo, onde:

- **Linhas**: usuários de treinamento (simulados).
- **Colunas**: livros do catálogo.
- **Células**: nota do usuário para aquele livro (em branco caso não avaliado).

Os dados foram gerados adotando perfis de usuário realistas, onde cada indivíduo tem gêneros e estilos favoritos que influenciam suas notas, com a adição de ruído gaussiano para simular um comportamento humano natural.

3 Modelo de Recomendação Baseado em Conteúdo (TF-IDF)

O modelo de filtragem baseada em conteúdo representa cada item como um vetor de características e recomenda itens similares àqueles que o usuário já apreciou.

3.1 TF-IDF

A técnica de *Term Frequency — Inverse Document Frequency* (TF-IDF) pondera a importância de cada termo (característica) nos livros:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t) \tag{1}$$

Onde:

- $\text{TF}(t, d) = \frac{n_{t,d}}{\sum_k n_{k,d}}$ (frequência do termo t no documento d).
- $\text{IDF}(t) = \log \frac{|D|}{|\{d : t \in d\}|}$ (inverso da frequência de documentos).

3.2 Similaridade de Cosseno

A similaridade entre o perfil do usuário $\vec{u}$ (calculado como a média dos livros curtidos) e um livro $\vec{v}$ do catálogo é dada por:

$$\text{sim}(\vec{u}, \vec{v}) = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\| \cdot \|\vec{v}\|} \tag{2}$$

4 Filtragem Colaborativa User-Based (kNN)

A filtragem colaborativa baseia-se no princípio de que usuários com gostos similares no passado tendem a ter gostos similares no futuro.

A similaridade de cosseno entre dois usuários (após centralização pela média das notas) é dada por:

$$\text{sim}(u, v) = \frac{\sum_{i \in I_{uv}} (r_{u,i} - \bar{r}_u)(r_{v,i} - \bar{r}_v)}{\sqrt{\sum_{i \in I_{uv}} (r_{u,i} - \bar{r}_u)^2} \cdot \sqrt{\sum_{i \in I_{uv}} (r_{v,i} - \bar{r}_v)^2}} \tag{3}$$

A predição da nota de um usuário u para um item i utiliza a média ponderada dos K-vizinhos mais próximos ($N_k(u)$):

$$\hat{r}_{u,i} = \bar{r}_u + \frac{\sum_{v \in N_k(u)} \text{sim}(u, v) \cdot (r_{v,i} - \bar{r}_v)}{\sum_{v \in N_k(u)} |\text{sim}(u, v)|} \tag{4}$$

5 Modelo Híbrido (Conteúdo + Colaborativo)

O modelo híbrido combina as predições dos dois modelos anteriores ponderando seus *scores* normalizados. O parâmetro α controla o equilíbrio entre eles:

$$\text{score_híbrido}(i) = \alpha \cdot \text{score_conteúdo}(i) + (1 - \alpha) \cdot \text{score_colaborativo}(i) \tag{5}$$

Onde $\alpha \in [0, 1]$ é o peso dado ao modelo de conteúdo.

6 Avaliação dos Modelos

Os algoritmos são avaliados utilizando o protocolo **Leave-One-Out (LOO)**: para cada usuário, remove-se uma avaliação alta do histórico, geram-se recomendações com o restante e verifica-se se o item removido aparece no top-K.

As principais métricas utilizadas são:

$$\text{Precision@K} = \frac{|\text{itens relevantes} \cap \text{top-}K|}{K} \tag{6}$$

$$\text{Recall@K} = \frac{|\text{itens relevantes} \cap \text{top-}K|}{|\text{itens relevantes}|} \tag{7}$$

Para a avaliação de erro do sistema colaborativo, utiliza-se a raiz do erro quadrático médio (RMSE):

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(r_i - \hat{r}_i)^2} \tag{8}$$

Referências

[1] Salton, G., & McGill, M. J. (1983). *Introduction to Modern Information Retrieval*. McGraw-Hill.

[2] Pazzani, M. J., & Billsus, D. (2007). Content-Based Recommendation Systems. *The Adaptive Web*, LNCS 4321.

[3] Resnick, P. et al. (1994). GroupLens: An Open Architecture for Collaborative Filtering. *CSCW*.

[4] Herlocker, J. et al. (2004). Evaluating Collaborative Filtering Recommender Systems. *ACM TOIS*, 22(1), 5–53.